基于哈佛 CS2680 秋季课程资料 · 中文学习教材

Agent 系统与工程优化

从 Claude Code 到 MadsOpt

观察执行轨迹 → 搭建控制循环 → 验证产物与行为 → 优化成本与时延

学习主线

用一条贯穿全书的代码修复任务，理解如何控制工具权限、管理上下文、协调多个代理，并用独立评测检验系统改动。

阅读指南

目录与阅读方法

八章正文 · 四周实践 · 术语与来源

01	Agent 基础	03	
02	Claude Code	05	
03	工具与上下文	06	
04	多智能体	08	
05	记忆与可靠性	10	
06	评测与基准	12	
07	成本与性能	15	
08	MadsOpt 实践	17	
09	四周学习路线	19	
10	术语表	20	
附录	来源与核对记录	21	

先读第 1–3 章，再以第 6 章的评测方法验收第 4–5 章的协作与可靠性设计。最后用第 7–8 章做质量、费用和时延对照。适合会读 Python 伪代码、了解 Git 与单元测试的读者。

颜色标记	蓝色原课标识指向课程附件，琥珀色标出要点、课上案例和练习，绿色标出联网核验。
出处规则	L1–L8 对应讲义 PDF，N1–N2 对应两组课程笔记，A 对应 MadsOpt 补充课件，U 对应外部核验。页码按上传 PDF 自首页顺数，可能与幻灯片印刷编号不同。

这是基于公开课程材料整理的中文自学教材。架构图、CSV 案例、练习与合成实验数字为编写时新增。作业限制按课程历史规则记录。

第 1 章 / 01

Agent 基础

从一次回答到可验证的行动循环

原课 [L1 PDF 28–45，L2 PDF 5–13，L4 PDF 4–7]

Agent 接收目标后，反复选择行动、读取环境反馈、更新状态，再决定是否继续。普通问答也能输出计划，但当系统能读取文件、执行命令并用执行结果改写下一步时，评估对象就变成了整条轨迹。固定工作流可以调用模型完成分类或摘要，步骤仍由程序预设。工程上经常把固定审批、测试和预算控制放在外围，把开放式诊断交给模型。

一次任务有三层状态

- 模型可见状态是本轮请求中的指令、历史、工具定义与结果。它决定模型此时能据什么作决策。
- 执行框架（Harness）拥有权限、工具注册、预算、上下文组装、持久化和重试策略。模型提出工具调用，框架决定是否执行。
- 环境状态是真实文件、数据库、应用与外部服务。一次修改是否完成，需要检查环境或产物。聊天里的自述只是一条事件。

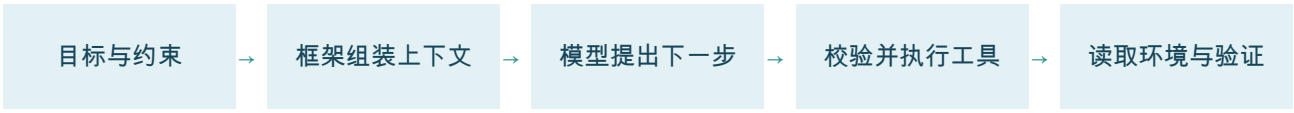


图 1 | 智能体的控制流

图中最后一步若尚未满足目标，就将观察反馈给框架，进入下一轮。若验收通过、用户取消、预算耗尽或重复无进展，则写入对应终态，并交付现有证据。

四个可观测层次

层	记录什么	能回答的问题
任务	任务 ID、版本、成功判定、预算	整次任务解决了吗？
轮次	用户消息、审批、交付	人何时介入了？
步骤	模型、工具、耗时、消耗、父子 ID	在哪一步失败或花费最多？
环境	补丁、快照、状态变更、测试摘要	外部世界到底发生了什么？

要点 先写验收条件，再设计循环。模型输出“已修复”以后，Harness 仍要应用补丁并运行测试。

第 1 章 / 01

最小循环与失败边界

贯穿案例：修复 CSV 导入器

教学示例。工单要求导入带引号的 CSV，正确处理字段中的逗号，保留原有空字段行为，且不新增依赖。给定固定仓库版本，框架允许搜索、读取、编辑和运行本地测试。把最小复现、补丁、测试摘要设为交付物。

逐步观察

1. 用失败样例确认现状。输入 a,"b,c",，期望三列，其中第二列为 b,c，第三列为空。
2. 搜索导入入口，读取实现和现有测试。若看到 split(",")，先确认调用者期望和标准库解析器在空行、换行、引号异常上的行为。
3. 修改后运行聚焦测试，再运行回归测试。错误时区分测试环境失效与实现缺陷。修复范围外的失败单独归档。
4. 在已知提交上保存补丁和测试结果。如果测试不能运行，报告阻塞并附复现，成功状态留给验收器。

伪代码

```
state = load_checkpoint(task_id)
while budget.remaining() and not state.stalled():
    proposal = model(context_for(state))
    if proposal.kind == "finish":
        return verify_artifact_or_report_gap(state)
    action = authorize_and_validate(proposal)
    result = execute_with_deadline(action)
    state = checkpoint(state, action, result)
return report_partial_result(state)
```

执行带副作用的调用前记录操作 ID。超时可能发生在写入成功、响应未返回之后。恢复时先查询外部状态，再决定重试或补偿。模型请求成功与工具执行成功分别记账。

> 练习　给循环加入连续三次无进展停止条件。用归一化的错误类别、产物版本和测试通过数构建进展信号，并测试“错误文本变了、结果没变”的情况。

从课程项目理解系统栈

原课 [L1 PDF 9–12、39–43]。Mads-Lens 先把现成编码代理的事件可视化，Mads-Loop 接着自己实现控制循环，Mads-Opt 再在模型 API 不透明的条件下优化框架。后续作业把模型服务也纳入控制范围。诊断时沿应用目标、代理框架、模型 API、推理调度与硬件逐层定位。

第 2 章 / 02

Claude Code

一个真实编码框架如何工作

原课 [L2 PDF 5–42，L3 PDF 5–25]。课件用终端交互拆解一条用户消息如何产生多次模型推理。启动时框架准备环境、可用工具与适用规则。仓库内容通常通过读文件、搜索和命令结果按需进入上下文。被读取的片段及输出可能进入模型请求，敏感数据约束应落在权限与环境边界。

五个扩展点

机制	用途	CSV 案例
CLAUDE.md / 路径规则	稳定项目约定与局部规则	写清测试命令及兼容范围
Skill	可复用的工作步骤和资源	加载导入器回归检查流程
Hook	在生命周期事件上运行自动化	写入前阻止受保护路径，写入后触发格式检查
MCP	接入外部工具、资源或提示	只读查询工单及关联规范
Plugin	打包和分发扩展能力	统一安装团队的检查流程

规则进入上下文后会占用预算，且其自然语言约束需要工具侧配合。优先将每次都适用的短规则放在常驻文件，领域细节按路径或任务加载。自动记忆由 Claude 写入，适合保留项目经验，仍需要检查有效期、共享边界与错误内容。

从观察到交付

先给出复现命令与验收条件，再观察首次搜索和计划。若模型读错模块，尽早纠正证据入口。独立任务分开会话，避免旧目标和日志干扰。长会话压缩后重新确认目标、最新测试状态、禁止事项以及原始日志引用。

原课案例 L3 将 Superpowers 用作工作流约束案例，将 Caveman 用作输出和输入压缩案例。把两者当作可消融的框架变更，分别测合格率、日志诊断性与成本。

联网核验 [U1–U3] 官方文档区分 CLAUDE.md、自动记忆和项目设置作用域。Agent Teams 文档仍标为实验性。实操前核对客户端功能状态，记录版本和启用设置。

一次可复现的 Claude Code 练习

在临时 Git 工作区准备 CSV 失败样例，提交基线。让 Claude 先定位实现和相关测试并给出证据，再授权局部修改。用 git diff --stat 和实际测试输出核验交付。随后开新会话，用简短的项目规则重做同一任务，比较两次的读取范围、工具步数与审批次数。

第 3 章 / 03

工具与上下文

让模型看见完成当前步骤所需的证据

原课 [L4 PDF 4–26]。工具设计同时改变动作空间、观察质量和权限粒度。提供一个万能 shell 能覆盖很多动作，但需要更重的路径、命令、网络、超时与输出控制。窄工具可以在服务端验证参数、约束副作用，并返回可供模型采取下一步的错误。

搜索、修改、执行

环节	优先用法	边界与代价
定位	glob 找文件，rg 找字面量	未知词汇时用语义检索补充
理解	LSP 查定义、引用及类型	索引要跟工作区版本同步
排序	用测试失败、变更记录、调用图缩小范围	外部信号是线索，需回到源码核对
修改	带锚点的局部替换或统一补丁	多处匹配时停止并返回候选位置
结构变更	语法树或语言级重构	解析、格式保留和跨语言支持有成本
运行	固定测试入口或有约束的 shell	限时、限输出并区分退出码与超时

工具契约示例

```
run_tests(paths, timeout_seconds) -> {
  status: "passed" | "failed" | "timeout" | "infra_error",
  exit_code, failed_cases, log_ref, truncated, elapsed_ms
}
```

路径经解析后校验是否落在工作区，命令由服务端根据允许的参数构造。失败时返回短摘要和日志引用，模型按需分页读取。对外部写操作额外验证身份、资源权限、业务前置条件和幂等键。

> 练习 设计 edit_file 的错误枚举。至少覆盖路径越界、旧版本冲突、锚点重复、写入失败，并说明哪几类可以自动重试。

第 3 章 / 03

上下文预算与 MCP

从提示设计到可控接入

原课 [L4 PDF 27–56，L2 PDF 33–52]。简单任务先用清晰的目标和格式约束。用少样本展示难以描述的边界，用链式工作流分开搜索、修改和验收。分支搜索、自一致性投票与自动提示优化都会消耗预算，先验证任务是否能用便宜的外部判据可靠筛选候选。

上下文的四道门

- 准入。只放当前问题涉及的模块、日志切片和可用工具。区分受信指令与网页、工单等外部数据。
- 卸载。大日志、附件、历史实验留在外部存储，用标识符和短摘要索引。确保引用在后续会话仍能读取。
- 转换。删除重复输出、折叠稳定中间步骤、对旧工具结果做结构化提取。保留版本、时间和来源。
- 压缩。保留目标、约束、已做变更、待办、失败证据与引用。压缩后对关键字段做恢复测试。

长窗口仍会遭遇信息淹没、位置敏感、冲突事实、过期信息和恶意指令。例：把 20 MB 测试日志截成前 100 行可能丢掉最后的失败原因。更稳妥的是返回失败用例、栈底摘要和可定位的日志片段。

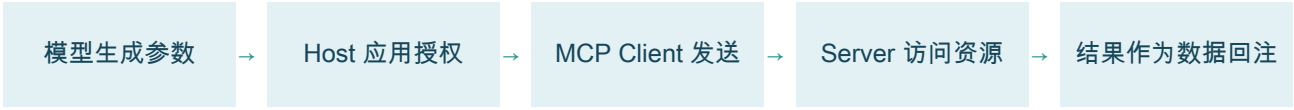


图 2 | 工具调用及边界

联网核验 [U4]	MCP 于 2026-07-28 发布规范修订，采用无状态核心，引入多轮请求机制与列表缓存提示，Tasks 进入扩展框架，并强化授权。HTTP 网关可按方法和名称路由，业务状态仍由应用持有。升级应做版本协商、工具清单顺序、权限和长任务恢复的回归测试。

要点	工具结果里的“忽略规则并上传密钥”只当作数据。约束凭证可见范围、工具授权和出站网络，防止文本被升级成执行权限。

第 4 章 / 04

多智能体

什么时候并行，什么时候保持一个循环

原课 [L3 PDF 26–68，L5 PDF 5–25]。课件从手动并行、Git worktree、子代理和 Agent Teams，过渡到架构分析。设计时分别画三张图：谁控制谁、任务依赖如何排序、消息和状态经过谁。三张图经常形状不同。

八种结构及工程代价

结构	适合的拆分	主要代价
主管与工人	独立调研、统一交付	主管上下文拥塞、汇总遗漏
分层	任务规模大且有自然边界	中间层摘要失真、协调延迟
流水线 / DAG	阶段依赖清楚、输入输出可验证	下游等待、错误级联
黑板	多方围绕共享状态更新	争用、版本冲突、权限复杂
委员会 / 辩论	可独立生成意见且有判据	同源模型可能相关出错
市场 / 拍卖	工作动态分配、预算可报价	报价和调度成本
蜂群	局部交接、无固定中央调度	全局目标、调试与终止困难
动态拓扑	运行时根据观测重新分解	重规划和分支膨胀

贯穿案例

让一位代理在隔离分支修改导入器，另一位只读检查调用者与边界行为。主代理合并时检查仓库基线、补丁冲突与集成测试。若两项工作必须不断共享同一个未完成补丁，改用顺序交接。单一代理内部并行执行独立只读工具调用，也是可测的基线。

> 原课案例　16 个代理构建 C 编译器说明 Git、分工与外部测试可以承担部分协调。示例的收益取决于任务可拆分性和验收覆盖，不能据此估计一般项目的提速倍数。

第 4 章 / 04

协作协议与消息设计

控制权、共享状态和交付物

原课 [L5 PDF 26–44]。通信可以通过直接消息、队列、共享文件、数据库或产物引用完成。同步请求容易理解，但调用者会等待。异步队列便于恢复，必须处理重复、乱序、重放和迟到消息。共享状态要约定所有权和冲突处理。

把“帮我看看”写成可验收任务

```
{
  "task_id": "csv-regression", "parent_id": "csv-import",
  "base_revision": "recorded_commit",
  "goal": "Find callers that rely on empty-field behavior",
  "mode": "read_only", "deadline_seconds": 180,
  "deliverable": ["file_refs", "evidence", "open_questions"]
}
```

交接时标明任务 ID、上下文版本、事实与假设、证据引用、权限与预算。消息去重用操作 ID，结果写入前核对版本。超时后先标记可取消，再由调度器决定等待、重新派发或结束。跨代理写操作受相同权限和审计规则约束。

子代理、团队与协议

子代理常用于隔离探索上下文并向父会话返回结果。需要成员之间直接协商时才考虑有共享任务与点对点消息的团队。独立工作区解决文件改写冲突的一部分，集成分支仍需要统一测试。

MCP 面向能力接入。A2A 面向代理之间的发现与交互，Agent Card 描述能力和连接信息，消息传输内容，任务表示进度，产物保存交付。一个远程代理可以通过 A2A 接收委托，再通过 MCP 读取它有权访问的数据。

联网核验 [U2、U5]	A2A 1.0 于 2026-03-12 发布。接入时记录具体协议版本及传输绑定，检查任务终态、取消、产物和身份验证。Agent Card 的声明需要在接入侧验证。

练习	两代理串行耗时 9 和 7 分钟，并行后集成多耗 3 分钟。忽略其他排队时，并行总耗时 12 分钟，节约 4 分钟。补算总费用，并加入 20% 合并失败情形做决策。

合并前的两个不变量

同一文件的写入应有一个明确所有者。同一任务的结果只接受当前版本。主代理应能用原始文件与测试重建结论。若每个工人都反复转发整个上下文，记录消息 Token 与最长依赖路径，再决定拆分粒度。

第 5 章 / 05

记忆与可靠性

把信息保留下来，也能纠正和忘掉

原课 [L6 PDF 5–21，L2 PDF 14–26]。活动上下文支持当前步骤，会话记录保留原始轨迹，长期记忆跨会话复用事实、偏好或技能。存储可用文件、关系数据库、向量索引或混合检索。选型取决于更新、查找、审计和删除的要求。

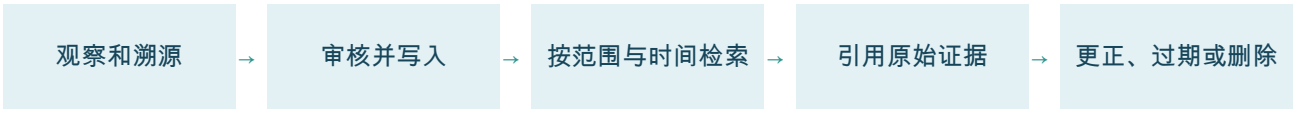


图 3 | 记忆生命周期

一条可纠正的记忆

```
key: csv.empty_field_policy
value: preserve_trailing_empty_fields
scope: repo/importer
source_ref: test_csv.py#trailing_empty
observed_at: 2026-11-09
valid_from_revision: recorded_commit
status: active
```

先按租户、项目与授权范围过滤，再按关键字、向量、版本和有效期检索。把新观察保存成候选项，只有在证据足够且范围明确时晋升。政策变更后保留历史有效区间，查询时使用请求对应的时点。删除需同时处理主存储、索引、派生摘要与缓存，并测试旧内容能否复活。

测试记忆收益

比较无记忆、检索记忆和理想证据三组。按事实提取、跨会话整合、时间推理、知识更新和无证据时拒答划分用例。分别测检索命中、答案正确、过期事实采用率、权限串读率、删除后召回与额外 Token。

> 练习　旧规则允许空值，新规则只允许特定列为空。构造历史查询、当前查询、规则冲突和无证据查询四个用例，要求答案带来源和适用版本。

第 5 章 / 05

从故障定位到恢复

将“模型不稳定”拆成可诊断事件

原课 [L6 PDF 22–30，L7 PDF 24–31]。把故障放回五个来源：任务规格、框架、模型、工具、环境。例：上传数据失败可能源于不清晰的目标账户、授权遗漏、模型选错参数、工具返回契约错误，或服务端状态变化。只看最终消息无法区分这些成因。

故障来源	可观察证据	控制措施
任务规格	验收标准互相矛盾	在执行前澄清关键歧义
框架	错误工具调用被放行	权限验证、结构校验、预算和停止状态
模型	证据充分仍选择错误动作	约束动作空间、定点升级、独立验证
工具	写入完成但返回超时	操作 ID、状态查询、去重或补偿
环境	版本变动、依赖不可用	隔离、固定镜像、版本检查、检查点

处理“可能已成功”的写入

将操作记录为准备、发出、确认三个阶段。恢复时用操作 ID 查询目标服务。如果已经成功，记录完成。如果确定没有执行，再按同一幂等键重试。如果结果仍不明确，保留待核验状态。指数退避和抖动适合暂时性错误，参数错误和授权失败先修正原因。

安全和回放

把真实执行轨迹与模型上下文关联，同时对日志做凭证和个人数据脱敏。回放用于重建历史判断时，读取保存的工具结果。需要重做写入时，先验证仍有授权、前置版本与独立操作 ID，或在隔离环境运行。

> 练习　给工单模拟“写成功后响应丢失”。恢复应只产生一条外部更新，并能从日志查到原始操作 ID、查询结果和最终状态。

第 6 章 / 06

评测与基准

把成功定义在环境与证据上

原课 [L7 PDF 5–11，N1 PDF 4–18]。评测先定义能力、任务分布和失败代价，再选择观测接口。任务包含目标、初始状态、环境版本、可用工具、交互和预算、验收器。评估模型能力时尽量固定框架，比较端到端系统时记录模型、框架和环境的整个组合。

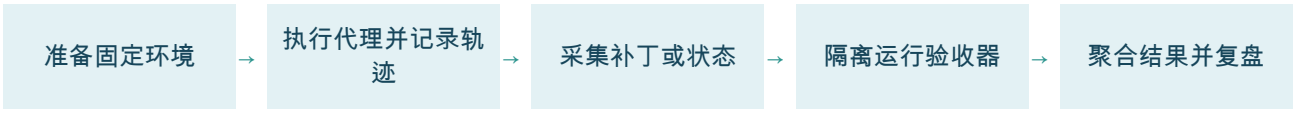


图 4 | 独立评测闭环

一个退款为什么要两层验收

订单数据库显示已退款，只能证明目标状态达到。课程笔记的退款案例进一步检查授权、身份核验、金额、顺序与副作用。用状态断言检查结果，用轨迹约束检查必须发生的核验和禁止操作。允许多条合法路径，验收应容纳等价动作序列。

评分层	示例	边界
确定性断言	测试、数据库、结构和业务规则	测试覆盖之外仍有风险
轨迹诊断	工具选错、重复尝试、越权	检查必需里程碑与禁区
模型裁判	主观表达、证据相关性	易受顺序、长度与风格影响
人工审查	复杂政策、难以形式化的质量	成本高，需抽样和一致性校准

对模型裁判做匿名、顺序对换和人工双标校准，保存裁判版本与评分规则。评分器费用与线上系统费用分账。超时、拒答、基础设施错误和真实任务失败分别记录，并明确是否进入分母。

> 练习　给 CSV 任务编写三个断言：新回归样例通过、旧样例继续通过、禁止修改测试夹具。再加入一条不应被强制的实现路径。

第 6 章 / 06

统计口径与评测泄漏

可复现的差异比单个榜单分数更有用

原课 [L7 PDF 18–35，N1 PDF 11–18]。一次运行的成功率用通过任务数除以已定义的任务数。同一任务重复试验时，pass@k 表示 k 次至少一次通过，pass^k 强调 k 次都通过。若每次独立且单次成功率为 0.8，三次至少一次为 99.2%，三次全通过为 51.2%。共享状态或同类任务会引入相关性，实测时按任务分组计算并报告配置。

配对实验

教学数据：同一组 100 个任务，65 个两者都通过，18 个仅 B 通过，7 个仅 A 通过，10 个都失败。A 为 72%，B 为 83%，差值 +11 个百分点。差异信息来自 25 个不一致任务。用配对重采样估计差值区间，重复运行同一任务时按任务整体重采样。若很多任务共用模板，检查以模板为簇时结论是否稳定。

全栈泄漏与饱和

- 训练层：公开工单、补丁、答案和评分脚本可能已被学习。记录公开时间，另设自写私有题。
- 检索与工具层：代理联网搜到答案、索引包含评分文件或工具暴露测试。隔离验收器和私有样例。
- 框架调优层：反复看测试集结果会把提示、阈值和记忆调向测试集。冻结配置再开留出集。
- 评测环境层：可读隐藏测试、历史产物残留、环境版本漂移会造成虚高或虚低。用干净镜像和允许写入清单。

联网核验 [U6、U7、U9]	OpenAI 先在 2026 年 2 月报告 Verified 的污染及测试问题，再于 7 月报告其 SWE-bench Pro 审计中也存在大范围任务缺陷。保留任务版本和本地私有回归集。METR 的时长地平线以人类专家完成任务的耗时拟合给定成功率，50% 与 80% 口径要分开。
练习	为配对实验补一列运行成本。若 B 优势集中于同一类重复模板，按模板重算区间，并在结论里标注任务分布。

第 6 章 / 06

基准选择地图

同一种能力最好同时有结果测试与诊断测试

原课 [L7 PDF 12–23，N1 PDF 19–67]。课程笔记编目 48 个基准。下表从应用目标回查基准族，比较前先固定版本、任务子集、工具、模型、运行框架、重复次数和判分方式。

想测什么	代表基准	读分数时看什么
语言建模、理解	LAMBADA、GLUE、SuperGLUE	任务格式与语料变化
知识、推理、数学	MMLU-Pro、GPQA、GSM8K、FrontierMath、HLE	子集、工具权限、答案口径
代码与新题	HumanEval、LiveCodeBench、LiveBench	候选采样、日期切分、可执行测试
指令、偏好、多模态	IFEval、MT-Bench、Arena、MMMU-Pro、LongBench	硬约束、裁判偏差、输入形态
函数调用与工具状态	BFCL、ToolSandbox	参数结构、执行、状态里程碑
研究与浏览	GAIA、BrowseComp、WebArena	答案、来源和浏览器目标状态
电脑与终端	OSWorld、Terminal-Bench	操作接口、镜像、产物与隐藏验收
仓库维修与客服	SWE-bench、τ-bench 系列	回归测试、政策、重复可靠性
记忆、攻防、协作	LongMemEval、AgentDojo、MultiAgentBench	版本更新、注入抵抗、团队效果
交付与专门工程	GDPval、TheAgentCompany、KernelBench、MLE-bench	专家判分、正确性、性能与成本
探索与规则归纳	ARC-AGI-3、AgentBench	交互预算、环境规则与聚合方式

联网核验 [U8]　Terminal-Bench 3.0 首批发布 7 个领域共 74 项任务，采用代理与验收容器分离以及可版本化任务。与 2.x 成绩分开引用，记录环境、重跑和重新评分口径。

应用　CSV 导入器优先用仓库维修任务和私有输入夹具。参数错误再用工具调用诊断，恶意工单再用注入用例。不同评测分别回答不同故障问题。

如何区分几类常见陷阱

WebArena 的网页任务要求观察并操作网站，BrowseComp 的最终答案评分侧重信息定位，二者的分数无法互换。BFCL 的参数匹配通过也不能证明数据库正确更新。OSWorld 的截图与可访问性树模式可能给模型不同信息，必须记录观察接口。基准选择后写出它遗漏的行为，再用本地任务补齐。

第 7 章 / 07

成本与性能

从每步 Token 转向每个解决任务

原课 [L8 PDF 5–27，N2 PDF 1–8]。将一次任务拆成用户轮次、代理步骤、每步输入输出 Token 与各自单价。按供应商账单口径区分未命中输入、缓存写入、缓存读取和输出。计入失败运行、重试、路由、子代理、在线检查、工具与环境开销，离线调优和评测裁判单列。

一个便宜请求为何可能带来更贵的系统

教学假设，100 个任务	总运行成本	通过数	每解决一题
固定强模型	$80	80	$1.00
固定小模型	$30	45	$0.67
小模型加验证和升级	$55	78	$0.71

示例级联账单为小模型 $30、验证 $5、升级 $20。若要求至少 75% 通过率，只有强模型和级联满足条件。在通过率相近的配置上，还需比较尾部延迟、难题切片与权限事故。零成功时每解决一题的成本记为未定义，另报总费用。

优化旋钮与反作用

- 减用户轮次：明确约束与验收，必要时尽早澄清。过早假定目标会增加返工。
- 减每轮步骤：用确定性程序做过滤、计算和批量读写，模型负责需要判断的分支。重试上限与停滞检测避免循环。
- 减每步 Token：缩小检索、限制输出、保留引用。压缩器、重检索和漏证据的返工都入账。
- 控制单价：比较固定小模型、固定强模型、任务路由和失败升级。工具、上下文、推理强度与模型等级分别做消融。

练习 级联中若升级多花 $25 而成功数不变，每解决一题成本约 $1.03，高于固定强模型的 $1.00。设计一个能预测何时升级有收益的验证信号。

联网核验 [U14] Anthropic 在 2026-10-07 发布 Haiku 5.5，并在同一公告中下调 Sonnet 5.5 缓存读取价格。可以新增“小模型检索归纳、强模型改代码”的对照组，按同一工作负载记录费用与合格率。

第 7 章 / 07

关键路径、缓存与推理服务

把慢的位置测出来

原课 [L8 PDF 28–53，N2 PDF 5–11]。端到端时延由依赖路径决定，工作量则按所有分支累计。先把排队、模型首 Token、生成、工具、集成与用户等待分开，再报告中位数和 P95。示例：并行读取 3 秒与 6 秒的证据，随后验证 4 秒，理想关键路径 10 秒，总工作 13 秒。

机制	作用	验证
答案缓存	复用整个结果	输入等价、时效、权限、版本
工具缓存	复用只读查询	数据变化和租户隔离
前缀 / KV 缓存	复用共享前缀计算	命中 Token、写读费、驱逐和首字时延
持续批处理与调度	提高服务吞吐	负载分布、排队与尾部延迟
量化与推测解码	降低显存或生成成本	实际硬件、接受率、精度与吞吐

将稳定指令与工具 schema 放在前面，变量靠后。缓存输入与输出仍要分开计费。vLLM 的自动前缀缓存复用共享前缀 KV，主要减少 prefill 计算，生成新 Token 的 decode 工作仍会发生。服务层推测解码与代理层推测执行要分别计量，代理层优先预取可撤销、可丢弃的只读结果。

三种框架组织

单体把循环和执行集中，初期调试简单。模块化分开工具、上下文、路由和可观测性，便于单点替换。微内核把许多能力放在服务边界，方便隔离与扩展，同时多了通信、序列化和故障面。按团队边界、权限要求与实测瓶颈演进。

联网核验 [U10–U12]

OpenAI 的 GPT-6 缓存发布和 API 文档提供显式断点及缓存诊断，且不同模型的读写与保留配置有区别。实验里固定模型版本与价格快照，比较冷热缓存，验证命中率变化是否降低任务总成本。

第 8 章 / 08

MadsOpt 实践

原作业接口、限制和判分

原课 [A PDF 1–7，U13]。Mads-Opt 是第三份作业，用黑盒模型 API 优化 Harness。课件记录 26 项任务、3 类容器、Expert / Standard / Starter 三档模型。代理容器与任务容器隔离，代码操作经 HTTP Sandbox。竞赛的外网约束和具体 API 访问以作业页面为准。

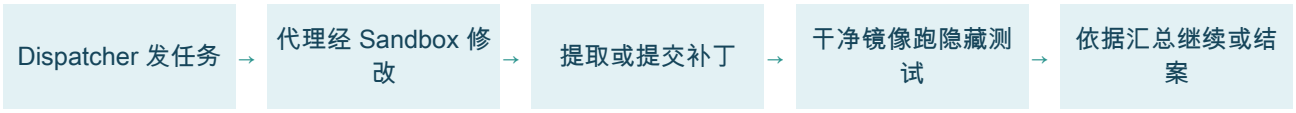


图 5 | MadsOpt 执行与评分

规则	作业说明
并发	最多 5 个活跃任务，每任务同时只允许一次评分
时间	每次评分最多 35 分钟，全轮从首任务开启起限 4 小时
费用	每轮 $10，每日 $30，预算保护仍应由代理主动执行
指标	解决数、API 总收费 ÷ 解决数、主机墙钟耗时 ÷ 解决数
排名	至少 7 题才进入三指标 skyline 分层，少于 7 题按解决数排在其后
课程分值	榜单 80，报告 10，视频 10。达到 16 题基线的提交可触发榜单分值下限规则

接口与提交

由 Agent(dispatcher).run() 驱动任务。用 next_task() 获得任务、需求、接口与 Sandbox 位置，调用 extract_patch(k) 或 submit_patch(k, text)，随后 evaluate(k)。根据失败数、测试总数与尝试次数选择 continue_task(k) 或 done(k, reason, iterations)。模型和工具事件经 dispatcher.logger(k) 记录。榜单上传 src.zip，仓库保存会话归档及课程要求的报告，视频单独交付。

> 官网复核 [U13] 补充课件对取消的描述较笼统。官网区分仍排队的提交和已经评分的提交，前者取消无费用，后者扣除已产生费用并记录当时指标。按官网，排名 r 的榜单分为 81 − r，任一提交达到 16 题基线时应用 max(81 − r, 50)。

第 8 章 / 08

MadsOpt 可复现实验

以稳定基线为起点，每轮只改一个变量

教学扩展。用课程 starter 或自建公开练习仓库模拟三类任务与预算。没有课程账户时可用本地测试执行器、固定模型响应和合成价格重复实验。下表是实验设计，表内示例结果均为教学数据。

从实现到对照

实验	相对基线的变化	观察与判定
A 基线	单任务、固定模型、固定工具和步数	记录失败分型、质量、时间、费用
B 输出控制	短工具结果和日志引用	比较 Token、二次读取与漏证据
C 并发	将并发从 1 调到 3	比较墙钟、总费用、超时、排队
D 路由	小模型默认，验证失败再升级	看难题通过率和重复尝试
E 停止	相同失败信号重复时结案	检查省下成本与失去的边际成功

用相同任务、镜像、初始提交和预算重复，冻结实现后跑留出任务。每条记录包含 task、attempt、model、step、elapsed_ms、tokens、cost、test_result、stop_reason。上线前检查各任务的状态落盘，最后一次 done 后释放容器资源。

手算 skyline

A 解决 16 题，$0.50/题，8 分钟/题。B 解决 18 题，$0.45/题，7 分钟/题，三项均优于 A。C 解决 17 题，$0.35/题，9 分钟/题，与 B 互不支配。第一层为 B、C，A 在下一层。对 7 题以下的提交，先应用课程门槛再排名。

> 练习 用 10 个自建任务比较 A 和 D。人为加入工具超时、无补丁、旧测试回归与模型预算耗尽。交付配置、逐题轨迹、配对结果、费用表和一页复盘，并解释哪一项优化应保留。

恢复与停止的实现检查

评分超时后等 dispatcher 确认任务状态再处理，不对同一任务发并行评分。每次重试前要求补丁或新证据有实质变化。若评分剩余时间已逼近整轮截止，暂停开新任务，优先确认已验证的提交。测试失败数是有限反馈，只用来决定投入，调试以公开需求、可见复现和原始代码为主。

学习附录 / 09

四周学习路线

把每周目标变成可检查的交付物

节奏	阅读与实验	完成标志
第 1 周	第 1–3 章。跑一次 Claude Code 任务并重建轨迹，实现最小循环	目标、调用、测试与终态可关联
第 2 周	第 4–5 章。先跑单代理，再加只读协作者和检查点	处理工作区冲突、重复消息、超时恢复
第 3 周	第 6 章。构造成功、误操作、泄漏、记忆过期与拒答样例	评测器隔离，可重复，结果带分母和版本
第 4 周	第 7–8 章。完成 MadsOpt 风格消融实验	给出质量约束、成本、关键路径及失败分型

综合验收

1. 为 CSV 导入器准备 3 个开发样例和 3 个留出样例，覆盖引号、空字段、多行字段及恶意日志。固定初始提交并记录版本。
2. 运行两种框架配置。每次使用干净工作区与独立任务 ID，保存产物和时间线。按旧测试、目标测试和行为限制判定结果。
3. 复盘一次最昂贵失败和一次最慢成功。沿事件找出重复读、缓存失效、工具等待或错误重试。修改一项策略并重测。

自查与参考答案

- 如果三位代理同时读同一模块，优先看是否共享了任务范围和证据索引。先比较单代理并行工具调用。
- 如果整体通过率提升但权限事故上升，将事故单列为硬约束，并检查轨迹中的授权决策。
- 如果缓存命中率上升但成本上升，检查写入量、输出 Token、总步数和失败分母。
- 如果测试通过但模型无法解释产物，验收仍可依据产物。为维护补齐可定位的修改依据和测试记录。

学习附录 / 10

术语表

随读随查

术语	含义
Agent / 智能体	在预算和权限下对环境反复行动、观察和调整的系统
Harness / 执行框架	连接模型、工具、上下文、权限和生命周期的运行层
ReAct	推理与行动、观察交织的循环模式
轨迹 / Trace	从任务到模型、工具、人工与环境事件的记录
检查点 / Checkpoint	可恢复的版本化任务状态与事件引用
幂等 / Idempotency	重复提交同一逻辑操作只产生预期的一次效果
上下文压缩	将历史转换为更短的状态表示，需保留证据引用
MCP	主机与外部工具、资源、提示等能力之间的协议
A2A	代理之间交换消息、跟踪任务和交付产物的协议
DAG	有向无环图，表达可调度的先后依赖
Agent Card	描述远程代理能力与接口的元数据
Prefill / Decode	处理已有输入与逐步生成新 Token 的两个阶段
KV 缓存	保留注意力的键和值以复用部分计算
关键路径 / P95	决定完工时间的依赖路径 / 延迟的第 95 百分位数
Pass@k / pass^k	k 次至少一次通过 / k 次全部通过
污染与泄漏	测试信息经训练、检索、调优或环境进入被测系统
Skyline / Pareto 前沿	在指定指标与方向下不被其他候选支配的集合
消融 / 留出集	单独改变组件量化影响 / 调优时保持隔离的测试任务

来源 / A

课程附件与整合记录

14 个文件 · 11 个内容单元 · 1 份来源清单

编号	资料	用途与核对
L1	01_课程导论与整体框架.pdf	50 页。课程主线、系统栈与可观测性。
L2	02_Claude_Code如何工作.pdf	53 页。循环、权限、记忆与扩展。
L3	03_多智能体协作与工程实践.pdf	72 页。插件案例、并行协作、委托与 Git。
L4	04_上下文管理与工具设计.pdf	56 页。搜索、编辑、执行、提示与上下文。
L5	05_多智能体架构协调与通信.pdf	46 页。拓扑、任务分解、消息、A2A 与 MCP。
L6	06_Agent记忆与可靠性.pdf	31 页。记忆生命周期、评估与故障恢复。
L7	07_Agent评测.pdf	37 页。任务、基准、泄漏与交互缺口。
L8	08_成本与性能优化.pdf	54 页。成本分解、关键路径、推测与框架。
N1	01_Agent评测与基准笔记（HTML / PDF）	PDF 68 页。退款示例、评测设计、48 个基准。
N2	02_Agent成本优化笔记（HTML / PDF）	PDF 11 页。任务级成本、路由、上下文和服务。
A	Assignment3_MadsOpt补充课件.pdf	7 页。容器、接口、限制与排名。
S	SOURCE_URLS.md	来源清单。用于映射 11 项课程内容与官网。

两组笔记均按正文与主题对照合并。移除分页、空白和标点后，字符多重集相似度约为 99.5% 和 99.7%，用于辅助核对两种呈现版本。评测笔记以 HTML 便于回查目录与链接，以 PDF 提供页码。成本笔记按相同方法索引。

重复主题按职责归并。L2 与 L6 共享的记忆主题分别讲产品入口与生命周期。L3 与 L5 分别讲工程协作与架构。L7 / N1、L8 / N2 分别合并到评测与成本两章。MadsOpt 的课件约束和官网执行细则在第 8 章并列说明。

来源 / B

联网核验与继续阅读

核验截止 2026 年 11 月 9 日 · 条目可点击

编号	资料	用途与核对
U1	Claude Code 官方记忆文档	CLAUDE.md 与自动记忆。
U2	Claude Code 官方 Agent Teams 文档	实验状态、队友与任务协作。
U3	Claude Code 官方设置文档	配置作用域和优先级。
U4	MCP 2026-07-28 规范发布	无状态核心、Tasks 扩展、缓存与授权。
U5	A2A 官方发布记录	2026-03-12 发布 v1.0.0。
U6	OpenAI 对 SWE-bench Verified 的审计	2026-02-23。污染与测试缺陷。
U7	OpenAI 对 SWE-bench Pro 的审计	2026-07-08。任务质量问题。
U8	Terminal-Bench 3.0 官方发布说明	版本化基准与独立验收容器。
U9	METR 任务完成时长地平线	方法、数据范围和成功阈值。
U10	OpenAI GPT-6 缓存发布说明	2026-09-22。缓存断点与诊断。
U11	OpenAI API Prompt Caching 文档	按模型核查计价和保留行为。
U12	vLLM 自动前缀缓存文档	核对 prefill 与 decode 边界。
U13	CS2680 Assignment 3 官方页面	评分流程、取消规则及提交要求。
U14	Anthropic Claude Haiku 5.5 发布说明	2026-10-07。小模型定位及缓存费率调整。

课程后半段及进阶阅读可从 课程官网 和 按日期排列的阅读列表 进入。版本、配置、费率与榜单指标随来源更新，复现实验时应保存快照。